

Perbandingan Pengklasifikasian Penyakit Parkinson Menggunakan Algoritma Naive Bayes, Random Forest, dan Regresi Logistik

Michael Emmanuel Purba¹, Angga Zefanya Situmorang², Muhammad Wahyu Pratama Lubis³

^{1,2,3}Universitas Mikroskil, Jl. Thamrin No. 112, 124, 140, Telp. (061) 4573767, Fax. (061) 4567789

^{1,2,3}Fakultas Informatika, Teknik Informatika, Universitas Mikroskil, Medan

e-mail: ¹211111304@students.mikroskil.ac.id, ²211111287@students.mikroskil.ac.id,

³211110731@students.mikroskil.ac.id

Dikirim: dd-mm-yyyy | Diterima: dd-mm-yyyy | Diterbitkan: dd-mm-yyyy

Abstrak

Penyakit Parkinson (PP) merupakan kondisi neurodegeneratif kronis dan progresif yang menjadi penyebab kedua tertinggi setelah Alzheimer. Penyakit ini disebabkan oleh kerusakan sel saraf pada substantia nigra dan akumulasi protein abnormal berupa Lewy bodies, dengan prevalensi yang meningkat pada kelompok usia lanjut. Penelitian ini bertujuan untuk membandingkan performa algoritma Naive Bayes, Random Forest, dan Regresi Logistik dalam mengklasifikasikan penyakit Parkinson menggunakan dataset dari Kaggle yang terdiri dari 2.105 data dengan 35 atribut. Tahapan preprocessing mencakup penghapusan atribut yang tidak relevan, pengecekan distribusi kelas, serta pembagian data latih dan uji secara stratifikasi. Hasil evaluasi menunjukkan bahwa algoritma Random Forest memiliki performa terbaik dengan skor ROC mencapai 0,97, menjadikannya model paling efektif untuk mendukung diagnosis dini penyakit Parkinson secara cepat, akurat, dan efisien.

Kata kunci: Penyakit Parkinson, algoritma Naive Bayes, Random Forest, Regresi Logistik, klasifikasi

Abstract

Parkinson's Disease (PD) is a chronic and progressive neurodegenerative condition, ranking as the second most common after Alzheimer's disease. It is caused by damage to nerve cells in the substantia nigra and the accumulation of abnormal protein aggregates known as Lewy bodies, with its prevalence increasing among the elderly population. This study aims to compare the performance of the Naive Bayes, Random Forest, and Linear Logistic algorithms in classifying Parkinson's disease using a dataset from Kaggle, consisting of 2,105 records with 35 attributes. The preprocessing steps included removing irrelevant attributes, checking class distribution, and stratified splitting of training and testing data. The evaluation results revealed that the Random Forest algorithm outperformed others with an impressive ROC score of 0.97, making it the most effective model for supporting early, accurate, and efficient diagnosis of Parkinson's disease.

Keywords: Parkinson's disease, Naive Bayes algorithm, Random Forest, Linear Regression, classification

1. PENDAHULUAN

1.1. Latar Belakang

Penyakit Parkinson (PP) merupakan salah satu penyakit neurodegeneratif yang paling sering terjadi, menempati peringkat kedua setelah Alzheimer [1]. Penyakit ini bersifat kronis, progresif, dan tidak dapat disembuhkan, sehingga memberikan dampak sosial yang signifikan. Pengobatan yang tersedia saat ini belum mampu menghentikan perkembangan penyakit ini dan sering kali disertai efek samping yang merugikan. Oleh karena itu, diperlukan alternatif terapi tambahan dengan risiko efek samping yang lebih rendah, seperti penggunaan vitamin [2]. Gejala Parkinson yang dapat dikenali meliputi rasa lemas atau kekakuan pada tubuh serta tremor atau getaran halus pada salah satu tangan. Selain itu, penyakit ini memengaruhi substantia nigra, area kecil di otak tengah yang berfungsi mengirimkan sinyal ke saraf tulang belakang untuk mengontrol otot tubuh [3].

Prevalensi penyakit Parkinson di negara-negara industri diperkirakan mencapai 0,3% dari total populasi, dengan sekitar 1% pada individu yang berusia di atas 60 tahun. Angka ini meningkat seiring bertambahnya usia, baik pada pria maupun wanita. Di Eropa, prevalensi Parkinson pada usia 85-89 tahun dilaporkan sebesar 3,5% [4]. Insiden penyakit ini berkisar antara 10 hingga 50 per 100.000 orang per tahun, dengan prevalensi mencapai 100 hingga 300 per 100.000 populasi. Frekuensi Parkinson meningkat tajam sesuai dengan bertambahnya usia [5]. Insiden terjadi pada dekade keenam kehidupan, meskipun kasus dengan onset lebih awal dapat ditemukan pada dekade keempat [6]. Parkinson jarang terjadi sebelum usia 50 tahun, tetapi insidensi dan prevalensinya meningkat secara signifikan setelah usia 60 tahun. Berdasarkan studi meta-analisis, prevalensi Parkinson meningkat dari 107 per 100.000 pada usia 50-59 tahun menjadi 1.087 per 100.000 pada usia 70-79 tahun [5]. Karena kaitannya dengan usia, jumlah kasus Parkinson diproyeksikan meningkat sebesar 25-30% dalam 25 tahun mendatang. Prevalensi tertinggi penyakit ini tercatat pada ras Kaukasia di Amerika Utara dan Eropa (0,98% hingga 1,84%), sedangkan prevalensi lebih rendah ditemukan pada ras Asia (0,018%) dan yang terendah pada ras kulit hitam di Afrika (0,01%) [7].

Penelitian ini bertujuan untuk mengatasi tantangan dalam mendiagnosis penyakit Parkinson dengan mengevaluasi dan membandingkan kinerja tiga algoritma pembelajaran mesin, yaitu Naive Bayes, Random Forest, dan Regresi Logistik. Ketiga algoritma tersebut dipilih berdasarkan pendekatan unik yang ditawarkan, seperti analisis probabilistik, metode berbasis pohon keputusan, dan model prediksi linier. Penelitian ini diharapkan dapat memberikan panduan dalam menentukan algoritma paling efektif untuk mendukung diagnosis dini sekaligus meningkatkan akurasi deteksi penyakit Parkinson. Dalam penelitian sebelumnya, pendekatan Naive Bayes dan Random Forest dibandingkan. Hasil menunjukkan bahwa metode Naive Bayes memiliki akurasi 49,06%, Random Forest 74,28%, C4.5 57,53%, Bayesian Network 48,07%, dan Decision Stump 49,95%, dengan Random Forest memberikan performa lebih baik dibandingkan lainnya [3], [8]. Menurut penelitian yang dilakukan oleh Chandel, Kunwar, Sabitha, Choudhury, dan Mukherjee pada 2017 tentang perbandingan deteksi penyakit tiroid menggunakan klasifikasi K-Nearest Neighbor (KNN) dan Naive Bayes, algoritma KNN menunjukkan akurasi 93,44%, sedangkan Naive Bayes hanya 22,56% [9].

Penelitian ini juga bertujuan untuk mengidentifikasi algoritma yang paling efektif dalam meningkatkan akurasi diagnosis dini guna mendukung pengembangan metode diagnosis yang lebih cepat, efisien, dan akurat. Penelitian ini diharapkan memberikan kontribusi signifikan terhadap pengembangan teknologi cerdas dalam diagnosis penyakit neurodegeneratif, khususnya Parkinson, baik untuk penelitian maupun aplikasi klinis. Data yang digunakan dalam penelitian ini berasal dari situs Kaggle, dengan total 2.105 data yang digunakan untuk melatih dan mengevaluasi model. Dataset ini dipilih karena relevan dengan tujuan penelitian, yaitu meningkatkan akurasi diagnosis dini penyakit Parkinson. Data tersebut mencakup berbagai fitur yang mendukung analisis pola dan pengambilan keputusan yang lebih baik dalam identifikasi penyakit.

1.2. Rumusan Masalah

Penyakit Parkinson adalah salah satu penyakit neurodegeneratif yang bersifat progresif dan tidak dapat disembuhkan, dengan dampak sosial yang signifikan karena keterbatasan pengobatan yang ada saat ini. Diagnosis dini sangat penting untuk memperlambat perkembangan penyakit dan meningkatkan

kualitas hidup pasien, namun metode konvensional sering kali memiliki keterbatasan dalam hal akurasi. Dalam konteks ini, penerapan pembelajaran mesin berpotensi menjadi solusi yang efektif dalam mendukung diagnosis dini penyakit Parkinson. Berdasarkan latar belakang tersebut, rumusan masalah yang diangkat dalam penelitian ini adalah:

1. Bagaimana performa algoritma pembelajaran mesin, yaitu Naive Bayes, Random Forest, dan Regresi Logistik, dalam mendeteksi penyakit Parkinson secara akurat?
2. Algoritma mana yang paling efektif dalam meningkatkan akurasi diagnosis dini penyakit Parkinson berdasarkan data yang tersedia?
3. Sejauh mana penerapan pembelajaran mesin dapat berkontribusi dalam pengembangan metode diagnosis yang lebih cepat dan akurat?

1.3. Tujuan

Penelitian ini bertujuan untuk:

1. Menganalisis dan membandingkan performa tiga algoritma pembelajaran mesin, yaitu Naive Bayes, Random Forest, dan Regresi Logistik, dalam mendeteksi penyakit Parkinson.
2. Mengidentifikasi algoritma yang memberikan akurasi terbaik untuk deteksi dini penyakit Parkinson.
3. Mendukung pengembangan metode diagnosis berbasis teknologi cerdas yang lebih cepat, efisien, dan akurat untuk mendukung penelitian maupun aplikasi klinis.

1.4. Ruang Lingkup

Adapun batasan masalah yang ditetapkan dari penelitian ini adalah sebagai berikut:

1. Penelitian menggunakan dataset berjumlah 2.105 data yang diunduh dari situs Kaggle, dengan fitur-fitur relevan yang mendukung diagnosis penyakit Parkinson.
2. Fokus penelitian terletak pada penerapan dan evaluasi tiga algoritma pembelajaran mesin, yaitu Naive Bayes, Random Forest, dan Regresi Logistik.
3. Pengukuran kinerja algoritma didasarkan pada metrik akurasi dalam mendeteksi penyakit Parkinson, serta dilakukan perbandingan dengan hasil penelitian sebelumnya.
4. Penelitian ini tidak mencakup pengembangan algoritma baru, melainkan memanfaatkan algoritma yang sudah ada untuk mengevaluasi efektivitasnya dalam diagnosis penyakit Parkinson.

2. TINJAUAN PUSTAKA

2.1. Penyakit Parkinson


Penyakit Parkinson adalah gangguan neurodegeneratif yang menduduki peringkat kedua setelah Alzheimer dalam prevalensinya. Penyakit ini disebabkan oleh penurunan kadar dopamin di otak, yang berperan dalam mengontrol gerakan tubuh. Penurunan dopamin tersebut terjadi akibat kerusakan sel saraf di Substantia Nigra Pars Compacta (SNc) pada batang otak, serta penumpukan protein abnormal berupa Lewy bodies yang mengandung α -synuclein. Meskipun sudah banyak penelitian yang dilakukan, penyebab pasti dari penyakit Parkinson masih belum ditemukan. Penyakit ini termasuk salah satu gangguan sistem saraf dengan insidensi tertinggi setelah Alzheimer [10].

2.2. Pembelajaran Mesin

Teknologi machine learning (ML) adalah sistem yang dirancang untuk belajar secara otomatis tanpa memerlukan instruksi langsung dari pengguna. Machine learning dibangun dengan menggabungkan berbagai disiplin ilmu, seperti statistika, matematika, dan data mining, yang

memungkinkan mesin untuk menganalisis data secara otomatis tanpa perlu pemrograman ulang atau perintah tambahan [11].


Penelitian terkini mengidentifikasi tiga kategori utama dalam machine learning, yaitu Supervised Learning, Unsupervised Learning, dan Reinforcement Learning [12]. Skema keterkaitan antara artificial intelligence dan machine learning dapat digambarkan dalam Gambar 1.



Gambar 1. Skema keterkaitan artificial intelligence dan machine learning

2.3. Pembelajaran Supervised

Pada algoritma Supervised Learning, sistem diberikan dataset yang mencakup informasi masukan dan keluaran yang diinginkan. Dengan demikian, sistem dapat mempelajari pola dari data yang sudah ada. Setelah mempelajari pola tersebut, sistem akan menggunakannya sebagai referensi untuk menganalisis kumpulan data berikutnya. Gambar 2 menunjukkan diagram blok yang menggambarkan cara kerja dari Supervised Learning [13].



Gambar 2. Skema cara kerja supervised learning

2.4. Naïve Bayes

Algoritma Naïve Bayes adalah teknik klasifikasi yang menggunakan pendekatan probabilitas dan statistik, yang pertama kali diajukan oleh ilmuwan Inggris, Thomas Bayes. Prinsip dasar dari algoritma ini adalah memperkirakan kemungkinan di masa depan berdasarkan pengalaman masa lalu, yang dikenal

dengan Teorema Bayes [14]. Dalam algoritma ini, terdapat asumsi bahwa setiap atribut saling independen, yang dikenal dengan istilah "Naive." Artinya, dalam penerapannya, algoritma Naïve Bayes menganggap bahwa tidak ada hubungan antara satu atribut dengan atribut lainnya, meskipun sebenarnya atribut tersebut mungkin memiliki keterkaitan.

Pada tahap pelatihan, algoritma klasifikasi akan membangun model dengan menganalisis data pelatihan. Proses ini dapat dianggap sebagai pembentukan fungsi atau pemetaan dari $Y=F(X)$, di mana Y adalah kelas hasil prediksi dan X adalah tuple yang ingin diprediksi kelasnya [2]:

1. Menghitung nilai peluang kondisi baru (X_k) dari setiap hipotesa terhadap kelas (C_i) yang ada.
2. Menghitung nilai akumulasi peluang dari setiap kelas (C_i)
3. Menghitung Nilai $P(X|C_i) \times P(C_i)$
4. Menentukan kelas dari kasus baru tersebut.

Rumus Naive Bayes yang digunakan dalam proses analisis klasifikasi adalah sebagai berikut:

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)} \quad (1)$$

1. $P(C|X)$: Probabilitas posterior yang menunjukkan kemungkinan bahwa kelas C adalah benar, diberikan informasi fitur X .
2. $P(X|C)$: Probabilitas likelihood, yaitu kemungkinan data X muncul jika kelas C sudah diketahui.
3. $P(C)$: Probabilitas prior, yaitu peluang awal dari kelas C berdasarkan distribusi kelas dalam dataset.
4. $P(X)$: Probabilitas dari data X , sering dianggap konstan dalam perhitungan karena nilainya sama untuk semua kelas.

2.5. Random Forest

Random Forest adalah pengembangan dari metode Decision Tree yang menggabungkan beberapa Decision Tree, di mana setiap pohon keputusan dilatih menggunakan sampel individu, dan setiap atribut dipecah pada pohon yang dipilih secara acak dari subset atribut. Random Forest memiliki beberapa keunggulan, seperti peningkatan akurasi ketika ada data yang hilang, ketahanan terhadap outlier, dan efisiensi dalam penyimpanan data. Selain itu, Random Forest juga memiliki proses seleksi fitur yang memungkinkan untuk memilih fitur terbaik, sehingga meningkatkan performa model klasifikasi. Dengan adanya seleksi fitur, Random Forest dapat bekerja secara efektif pada big data dengan parameter yang kompleks [15].

Metode ini terdiri dari root node, internal node, dan leaf node. Root node adalah simpul yang terletak paling atas, sering disebut sebagai akar dari pohon keputusan. Internal node adalah simpul percabangan yang memiliki minimal dua output dan hanya satu input. Sedangkan leaf node, atau terminal node, adalah simpul terakhir yang hanya memiliki satu input dan tidak memiliki output. Pohon keputusan dimulai dengan menghitung nilai entropy sebagai indikator ketidakmurnian atribut, dan nilai information gain digunakan untuk menentukan pembagian terbaik. Untuk menghitung nilai entropy digunakan rumus seperti pada persamaan 2, sedangkan nilai information gain dihitung menggunakan persamaan 3 [16].

Berikut ini merupakan rumus dari Random Forest [17] :

$$Entropy(Y) = - \sum_i p(c|Y) \log^2 p(c|Y), \quad (2)$$

Keterangan :

Y : Himpunan kasus

$P(c|Y)$: Proporsi nilai Y terhadap kelas c .

$$Information\ Gain(Y, a) = Entropy(Y) - \sum_{v \in Values(a)} \frac{|Y_v|}{|Y_a|} Entropy(Y_v) \quad (3)$$

Keterangan :

$Values(a)$ = Nilai yang mungkin dalam himpunan a .

Y_v = Subkelas dari Y dengan kelas v yang berhubungan dengan kelas a .

Y_a = Semua nilai yang sesuai dengan a .

2.6. Regresi Liner

Dengan menggunakan regresi logistik, kita dapat menentukan bagaimana variabel respons dikotomis—yaitu variabel dengan dua kategori dalam skala nominal atau ordinal—terhubung dengan satu atau lebih prediktor yang berskala kategori atau kontinu [18].

Metode ini menghubungkan output biner dengan variabel independen berdasarkan probabilitas, untuk memprediksi nilai dari variabel dependen, yang kemudian akan mengklasifikasikan data ke dalam dua kategori yang berbeda [19]. Regresi logistik adalah salah satu metode klasifikasi yang umum digunakan. Regresi logistik biner digunakan ketika variabel dependen berupa variabel dikotomis. Menurut Hosmer, D.W., dan Lemeshow, S. (2000) dalam Purwa (2019) [20], secara umum, model regresi logistik adalah [21]:

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n}}{1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n}} \quad (4)$$

Dimana $\pi(x)$ adalah nilai probabilitas yang berada dalam rentang $0 \leq \pi(x) \leq 1$, yang berarti regresi logistik menggambarkan suatu probabilitas. Dengan mentransformasikan $\pi(x)$ pada persamaan di atas menggunakan transformasi logit $g(x)$, di mana:

$$g(x) = \ln\left(\frac{\pi(x)}{1 - \pi(x)}\right) \quad (5)$$

Maka diperoleh bentuk logit :

$$l = \log p \left(\frac{p_y}{1 - p_y} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n \quad (6)$$

Keterangan :

$l = \log\text{-odds}$, p adalah basis dari algoritma

β_n = adalah paramater model

p_y = adalah probabilitas dari kejadian tersebut

2.7. Evaluasi Model

Parameter recall, f1-measure, presisi, dan akurasi adalah beberapa metrik untuk mengukur kinerja algoritma, yang dapat dihitung berdasarkan confusion matrix yang ditunjukkan pada Tabel 1 [22].

Tabel 1. Tabel Confusion Matrix

	Label atau kelas	
	Positif	Negatif
Positif	True Positive	False Positive
Negatif	False Negative	True Negative

Pada tahap ini, pengujian dilakukan dengan menghitung nilai Akurasi, Sensitivitas, dan Presisi [23].

$$akurasi = \frac{TN + TP}{TN + TP + FN + FP} \quad (7)$$


Selain akurasi, performa klasifikasi juga dapat dinilai berdasarkan nilai sensitivitas dan spesifisitas. Sensitivitas mengukur akurasi pada kelas positif, sementara spesifisitas mengukur akurasi pada kelas negatif. Rumus untuk menghitung sensitivitas dan spesifisitas adalah sebagai berikut.

$$\text{Sensitivity} = \frac{TP}{(TP + FP)} \times 100\% \quad (8)$$

$$\text{akurasi} = \frac{TN + TP}{TN + TP + FN + FP} \quad (9)$$

3. METODE PENELITIAN

Pemecahan masalah dalam penelitian ini dimulai dengan pengumpulan data yang relevan, diikuti oleh tahap preprocessing untuk memastikan data siap digunakan oleh model. Setelah itu, data yang telah diproses diuji dengan tiga algoritma pembelajaran mesin, yaitu Naive Bayes, Random Forest, dan Regresi Logistik. Hasil dari setiap model kemudian dianalisis untuk menentukan algoritma yang paling efektif dalam mengklasifikasikan penyakit Parkinson, berdasarkan akurasi dan kinerja keseluruhannya.



Gambar 3. Alur Penelitian

3.1. Pengambilan Data

Dataset yang digunakan dalam penelitian ini diperoleh dari situs Kaggle, dengan total sebanyak 2.106 data yang terdiri dari 35 atribut. Dataset ini dipilih karena kelengkapan dan relevansinya dalam mendukung analisis serta pengklasifikasian penyakit Parkinson.

Gambar 4. Data yang didapatkan dari situs kaggle

3.2. Preprocessing

Pada tahap ini, data yang telah dikumpulkan akan melalui proses preprocessing untuk memastikan kualitas dan kelayakannya dalam melatih model secara optimal. Proses preprocessing yang dilakukan meliputi:

1. Hapus kolom yang tidak relevan
2. Pengecekan distribusi kelas
3. Pisahkan fitur dan target
4. Split data (80% data training dan 20% data testing)
5. Scaling data

3.3. Pelatihan Model

Pelatihan model merupakan bagian penting dalam metode penelitian yang bertujuan untuk menguji seluruh data menggunakan tiga algoritma yang telah ditentukan. Proses ini dilakukan untuk mengevaluasi kinerja setiap algoritma dan menentukan nilai atau persentase akurasi terbaik dalam klasifikasi penyakit Parkinson. Model yang akan diuji adalah :

1. Naïve bayes
2. Random forest
3. Regresi Logistik

3.4. Hasil Klasifikasi

Hasil klasifikasi merupakan output akhir dari proses pelatihan model terhadap data yang telah diproses. Pada tahap ini, akan terlihat model mana yang memiliki performa terbaik dibandingkan model lainnya dalam mengklasifikasikan penyakit Parkinson. Evaluasi ini dilakukan berdasarkan metrik tertentu, seperti akurasi, presisi, *recall*, dan F1-score, sehingga dapat memberikan gambaran yang jelas mengenai efektivitas masing-masing model dalam mendukung diagnosis penyakit Parkinson.

4. HASIL DAN PEMBAHASAN

4.1. Preprocessing

4.1.1. Hapus kolom yang tidak relevan

Pada tahap awal, dilakukan penghapusan kolom yang tidak relevan terhadap analisis, seperti *PatientID* dan *DoctorInCharge*. Kolom-kolom ini dianggap tidak berkontribusi pada proses klasifikasi karena *PatientID* hanya berfungsi sebagai identitas unik pasien, sedangkan *DoctorInCharge* merupakan atribut administratif yang tidak mempengaruhi diagnosis. Penghapusan kolom-kolom ini bertujuan untuk mengurangi kompleksitas data dan memastikan bahwa model hanya menggunakan fitur yang relevan.

4.1.2. Pengecekan distribusi kelas

Setelah data dipersiapkan, langkah berikutnya adalah memeriksa distribusi kelas pada target variabel (*Diagnosis*). Pengecekan ini penting untuk memastikan bahwa data terdistribusi

dengan seimbang antara kelas-kelas yang ada. Distribusi kelas yang seimbang membantu menghindari terjadinya bias pada model, di mana model lebih cenderung memprediksi kelas yang memiliki jumlah data lebih banyak. Jika distribusi kelas tidak seimbang, teknik seperti oversampling atau undersampling dapat dipertimbangkan.

4.1.3. Pisahkan fitur dan target

Proses berikutnya adalah pemisahan antara fitur (X) dan target (y). Fitur (X) adalah variabel independen yang digunakan untuk memprediksi target, sementara target (y) adalah variabel dependen yang ingin diprediksi oleh model, yaitu *Diagnosis*. Pemisahan ini penting untuk memastikan bahwa data siap untuk pelatihan model, sehingga fitur dapat diproses secara terpisah dari label yang ingin diprediksi.

4.1.4. Pembagian Data untuk Pelatihan dan Pengujian

Data kemudian dibagi menjadi dua bagian: 80% digunakan untuk pelatihan (*training*) dan 20% untuk pengujian (*testing*). Pembagian ini dilakukan dengan menggunakan stratifikasi untuk menjaga proporsi kelas yang sama antara data latih dan data uji. Stratifikasi memastikan bahwa setiap subset data (latih dan uji) memiliki distribusi kelas yang serupa dengan dataset asli, yang penting agar evaluasi model mencerminkan performa yang sebenarnya. Pembagian ini memungkinkan model untuk dilatih dengan data yang cukup dan diuji dengan data yang belum pernah dilihat sebelumnya.

4.2. Pelatihan model

4.2.1. Naïve Bayes

Algoritma Naïve Bayes adalah algoritma yang memperkirakan kemungkinan suatu data uji termasuk ke dalam kategori tertentu berdasarkan probabilitas dari setiap fitur data uji tersebut [24].

```
Confusion Matrix:
[[121  39]
 [ 40 221]]
True Positive (TP): 221
True Negative (TN): 121
False Positive (FP): 39
False Negative (FN): 40
Classification Report:

```

	precision	recall	f1-score	support
0	0.75	0.76	0.75	160
1	0.85	0.85	0.85	261
accuracy			0.81	421
macro avg	0.80	0.80	0.80	421
weighted avg	0.81	0.81	0.81	421


```

Akurasi Data Latih: 81.12%
Akurasi Data Uji: 81.24%

```

Gambar 5. Hasil uji Naïve Bayes

Setelah melakukan pelatihan pada data yang sudah di preprocessing, bisa disimpulkan bahwa sanya model yang digunakan untuk pengklasifikasian dapat dikatakan sangat baik, dengan akurasi pada data latih mencapai 97,57% dan akurasi pada data uji sebesar 93,35%. Namun, terdapat risiko overfitting karena model terlalu unggul dalam memproses data latih. Berdasarkan nilai F1-Score, dapat disimpulkan bahwa model bekerja lebih baik dalam mengklasifikasikan kelas 1 dibandingkan kelas 0. Untuk hasil evaluasi menggunakan ROC dapat dilihat pada gambar .



Gambar 6. Hasil evaluasi ROC pada model Naïve Bayes


4.2.2. Random forest

Random Forest adalah gabungan dari sejumlah pohon keputusan (*trees*) yang dibangun sedemikian rupa, di mana setiap pohon bergantung pada sampel acak (*random*) yang diambil secara independen dan memiliki distribusi yang sama untuk semua pohon dalam hutan (*forests*) [25].

Classification Report:				
	precision	recall	f1-score	support
0	0.92	0.90	0.91	160
1	0.94	0.95	0.95	261
accuracy			0.93	421
macro avg	0.93	0.93	0.93	421
weighted avg	0.93	0.93	0.93	421
Akurasi Data Latih: 97.57%				
Akurasi Data Uji: 93.35%				

Gambar 7. Hasil uji Random Forest

Model yang digunakan untuk pengklasifikasian dapat dinilai sangat baik, dengan akurasi pada data latih sebesar 97,57% dan akurasi pada data uji sebesar 93,35%. Namun, model ini masih berisiko mengalami overfitting karena performanya yang terlalu optimal pada data latih. Berdasarkan analisis F1-Score, model menunjukkan kinerja yang lebih baik dalam mengklasifikasikan kelas 1 dibandingkan kelas 0. Untuk hasil evaluasi menggunakan ROC dapat dilihat pada gambar .



Gambar 8. Hasil evaluasi ROC pada model Random Forest

4.2.3. Regresi Logistik

Regresi logistik (*logistic regression*) adalah bagian dari analisis regresi yang digunakan ketika variabel dependen (*respon*) berupa variabel dikotomi, yaitu yang terdiri dari dua nilai yang mewakili terjadinya atau tidaknya suatu kejadian, yang biasanya diberi angka 0 atau 1. Berbeda dengan regresi linier biasa, regresi logistik tidak mengasumsikan hubungan linier antara variabel independen dan dependen [26].

```
Confusion Matrix:
[[116  44]
 [ 32 229]]
True Positive (TP): 229
True Negative (TN): 116
False Positive (FP): 44
False Negative (FN): 32
Classification Report:
              precision    recall  f1-score   support


     0       0.78        0.72        0.75        160
     1       0.84        0.88        0.86        261

 accuracy          0.82        0.82        0.82        421
 macro avg         0.81        0.80        0.81        421
 weighted avg      0.82        0.82        0.82        421

Akurasi Data Latih: 82.13%
Akurasi Data Uji: 81.95%
```

Gambar 9. Hasil uji Regresi Logistik

Setelah dilakukan pelatihan, dapat disimpulkan bahwa model Logistic Regression memiliki performa yang baik dalam pengklasifikasian. Hal ini ditunjukkan oleh akurasi data latih sebesar 82,13% dan akurasi data uji sebesar 81,95%, yang menunjukkan perbedaan yang kecil sehingga model tidak mengalami underfitting maupun overfitting. Berdasarkan data F1-Score, model juga menunjukkan kinerja yang lebih optimal dalam mengklasifikasikan kelas 1 dibandingkan kelas 0. Untuk hasil evaluasi menggunakan ROC dapat dilihat pada gambar 10.



Gambar 10. Hasil evaluasi ROC pada model Regresi Logistik

4.3. Hasil Klasifikasi

Model Confusion Matrix akan digunakan untuk menguji akurasi prediksi yang dibuat berdasarkan hasil klasifikasi menggunakan algoritma perbandingan Naïve Bayes, Random Forest, dan Regresi Logistik dalam klasifikasi diagnosis penyakit Parkinson [3].

Tabel 2. Hasil perbandingan klasifikasi antar model

Jenis data	Akurasi		
	Naïve Bayes	Random Forest	Regresi Logistik
Data latih	81.12%	97.57%	82.13%
Data uji	81.24%	93.35%	81.95%

Dalam perbandingan performa ketiga model menggunakan skor ROC dan Matriks Konfusi, model Random Forest menunjukkan hasil yang sangat unggul dengan skor ROC mencapai 0,97. Hal ini mengindikasikan kemampuannya yang luar biasa dalam membedakan antar kelas secara efektif. Secara keseluruhan, model Random Forest muncul sebagai pilihan terbaik untuk tugas klasifikasi ini, berkat akurasinya yang tinggi dalam memprediksi hasil, menjadikannya model yang paling andal di antara model-model yang diuji.

5. KESIMPULAN

Kesimpulan dari penelitian ini menunjukkan bahwa model Random Forest unggul dalam mengklasifikasikan penyakit Parkinson dibandingkan dengan model lain yang diuji, seperti Logistic Regression. Dengan skor ROC yang mengesankan sebesar 0,97, atau 97% Random Forest mampu membedakan antara kelas dengan sangat baik, menunjukkan kemampuannya dalam menangani perbedaan yang kompleks antara kelas yang ada. Model ini juga menunjukkan akurasi yang tinggi baik pada data latih maupun data uji, menjadikannya pilihan yang paling andal dalam tugas klasifikasi ini.

Di sisi lain, meskipun model Logistic Regression memiliki akurasi yang baik dengan nilai yang hampir setara antara data latih dan data uji, serta tidak menunjukkan gejala underfitting atau overfitting,

Random Forest tetap menunjukkan performa superior dalam hal akurasi dan kemampuan prediksi yang lebih stabil.

Secara keseluruhan, model Random Forest terbukti menjadi model yang paling efektif dalam mengklasifikasikan penyakit Parkinson, dengan keunggulan dalam membedakan antara kelas serta ketahanan terhadap masalah overfitting. Hal ini membuatnya lebih dapat diandalkan dan cocok untuk digunakan dalam diagnosis dini penyakit Parkinson menggunakan data yang tersedia.

6. SARAN

Berdasarkan hasil penelitian ini, beberapa saran untuk penelitian selanjutnya adalah sebagai berikut:

1. Peningkatan Proses Preprocessing: Meskipun langkah preprocessing yang dilakukan sudah cukup efektif, kemungkinan ada fitur tambahan yang relevan namun belum dimanfaatkan sepenuhnya. Penelitian selanjutnya bisa lebih mengeksplorasi teknik seleksi fitur atau penerapan metode ekstraksi fitur lanjutan untuk meningkatkan akurasi model.
2. Eksplorasi Algoritma Lain: Penelitian ini hanya menggunakan tiga algoritma, yaitu Naive Bayes, Random Forest, dan Logistic Regression. Untuk penelitian lebih lanjut, bisa mencoba algoritma lain seperti Support Vector Machines (SVM), Gradient Boosting, atau Neural Networks, yang mungkin memiliki kemampuan lebih baik dalam mengklasifikasikan penyakit Parkinson.
3. Peningkatan Ukuran Dataset: Dalam penelitian ini, dataset yang digunakan berjumlah 2.105 data. Dengan jumlah data yang terbatas, penelitian berikutnya sebaiknya melibatkan dataset yang lebih besar atau menggabungkan data dari berbagai sumber, untuk meningkatkan akurasi dan generalisasi model. Penggunaan data yang lebih beragam dapat membantu model untuk memahami lebih banyak variasi terkait penyakit Parkinson.
4. Pengujian dengan Data Dunia Nyata: Untuk meningkatkan validitas temuan, uji model menggunakan data dunia nyata atau data klinis yang lebih luas dapat dilakukan. Ini dapat memberikan gambaran lebih jelas mengenai bagaimana model dapat diterapkan dalam kondisi nyata untuk mendukung diagnosis dini penyakit Parkinson.

DAFTAR PUSTAKA

- [1] S. Alia *et al.*, "Penyakit Parkinson: Tinjauan Tentang Salah Satu Penyakit Neurodegeneratif yang Paling Umum," *Aksona*, vol. 1, no. 2, pp. 95–99, 2022, doi: 10.20473/aksona.v1i2.145.
- [2] A. R. Onibala, C. D. Mambo, and A. S. R. Masengi, "Peran Vitamin dalam Penanganan Penyakit Parkinson," *Jurnal Biomedik (Jbm)*, vol. 13, no. 3, p. 322, 2021, doi: 10.35790/jbm.13.3.2021.31956.
- [3] W. Z. Aprilita, R. Akbar, R. Cahyadi Prayogi, T. Informatika, and S. Amik Riau, "SENTIMAS: Seminar Nasional Penelitian dan Pengabdian Masyarakat Comparison of K-Nearest Neighbor (KNN) and Naive Bayes Algorithms in the Classification of Parkinson's Disease Komparasi Algoritma K-Nearest Neighbor (KNN) dan Naive Bayes dalam Klasifikasi P," pp. 188–193, 2023, [Online]. Available: <https://journal.irpi.or.id/index.php/sentimas>
- [4] N. Fajar Susanti, S. Ns Ida Djafar, Mk. Ns Robiul Fitri Masithoh, Mk. dr Frisca Angreni, Mb. Deniyati, and Ms. dr Atika Indah Sari Ns Tria Prasetya Hadi, *Penyakit Muskuloskeletal*. 2024. [Online]. Available: <http://repository.uki.ac.id/15073/>
- [5] O. B. Tysnes and A. Storstein, "Epidemiology of Parkinson's disease," *J Neural Transm*, vol. 124, no. 8, pp. 901–905, 2017, doi: 10.1007/s00702-017-1686-y.

- [6] W. Muangpaisan, H. Hori, and C. Brayne, "Systematic review of the prevalence and incidence of Parkinson's disease in Asia," *J Epidemiol*, vol. 19, no. 6, pp. 281–293, 2009, doi: 10.2188/jea.JE20081034.
- [7] S. A. Tanazza and L. M. Erawati, "Analisis Intervensi Fisioterapi Pada Penyakit Parkinson Menggunakan Vosviewer," *Physio Journal*, vol. 2, no. 2, pp. 49–60, 2022, doi: 10.30787/phyjou.v2i2.877.
- [8] F. M. Januarsyah, E. Zuhairi, and R. M. Firsandaya, "Perbandingan Algoritma Random Forest, Decision Stump, Naïve Bayes, Bayesian Network dan Algoritma C4.5 Untuk Prediksi Pola Kartu Poker," *Prosiding Annual Research Seminar*, vol. 5, no. 1, pp. 122–126, 2019, [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/Poker+Hand>.
- [9] K. Chandel, V. Kunwar, S. Sabitha, T. Choudhury, and S. Mukherjee, "A comparative study on thyroid disease detection using K-nearest neighbor and Naive Bayes classification techniques," *CSI Transactions on ICT*, vol. 4, no. 2–4, pp. 313–319, 2016, doi: 10.1007/s40012-016-0100-5.
- [10] Linlin Lindayani, Dewi Marfuah, Diwa Agus Sudrajat, and Eva Supriatin, "Literature Review Efektivitas Latihan Aerobik Dalam Meningkatkan Fungsi Motorik Pada Lansia Dengan Penyakit Parkinson," *Risenologi*, vol. 6, no. 1a, pp. 100–108, 2021, doi: 10.47028/j.risenologi.2021.61a.220.
- [11] D. Intern, "Apa itu Machine Learning? Beserta Pengertian dan Cara Kerjanya," dicoding. [Online]. Available: <https://www.dicoding.com/blog/machine-learning-adalah/>
- [12] A. Roihan, P. A. Sunarya, and A. S. Rafika, "Pemanfaatan Machine Learning dalam Berbagai Bidang: Review paper," *IJCIT (Indonesian Journal on Computer and Information Technology)*, vol. 5, no. 1, pp. 75–82, 2020, doi: 10.31294/ijcit.v5i1.7951.
- [13] H. Abijono, P. Santoso, and N. L. Anggreini, "Algoritma Supervised Learning Dan Unsupervised Learning Dalam Pengolahan Data," *Jurnal Teknologi Terapan: G-Tech*, vol. 4, no. 2, pp. 315–318, 2021, doi: 10.33379/gtech.v4i2.635.
- [14] A. Z. Macfud, A. P. Kusuma, and W. D. Puspitasari, "Analisis Algoritma Naive Bayes Classifier (Nbc)," vol. 7, no. 1, pp. 87–94, 2023.
- [15] R. Supriyadi, W. Gata, N. Maulidah, and A. Fauzi, "Penerapan Algoritma Random Forest Untuk Menentukan Kualitas Anggur Merah," *E-Bisnis : Jurnal Ilmiah Ekonomi dan Bisnis*, vol. 13, no. 2, pp. 67–75, 2020, doi: 10.51903/e-bisnis.v13i2.247.
- [16] Y. S. Nugroho and N. Emiliyawati, "Sistem Klasifikasi Variabel Tingkat Penerimaan Konsumen Terhadap Mobil Menggunakan Metode Random Forest," *Jurnal Teknik Elektro*, vol. 9, no. 1, pp. 24–29, 2017.
- [17] G. A. Sandag, "Prediksi Rating Aplikasi App Store Menggunakan Algoritma Random Forest," *CogITO Smart Journal*, vol. 6, no. 2, pp. 167–178, 2020, doi: 10.31154/cogito.v6i2.270.167-178.
- [18] N. Ranti, M. 1*, K. H. Hanif, C. Nisa, S. Informasi, and B. Kaltara, "Perbandingan Algoritma Regresi Logistik, Support Vector Machine, dan Gradient Boosting Pada Analisis Sentimen Data Komentar Siswa," vol. 4, no. 2, pp. 27–32, 2023, [Online]. Available: <http://creativecommons.org/licenses/by/4.0/%0Ahttp://ejournal.uhb.ac.id/index.php/IKOMTI>
- [19] A. Regresi, "Penerapan CRISP-DM untuk Deteksi Eksoplanet menggunakan," vol. 4, pp. 160–169, 2024.
- [20] T. Purwa, "Perbandingan Metode Regresi Logistik dan Random Forest untuk Klasifikasi Data Imbalanced (Studi Kasus: Klasifikasi Rumah Tangga Miskin di Kabupaten Karangasem, Bali Tahun 2017)," *Jurnal Matematika, Statistika dan Komputasi*, vol. 16, no. 1, p. 58, 2019, doi: 10.20956/jmsk.v16i1.6494.
- [21] A. Salim and M. R. Alfian, "Optimalisasi Regresi Logistik Menggunakan Algoritma Genetika Pada Data Klasifikasi," *Jurnal Teknologi Informasi dan Terapan*, vol. 6, no. 2, pp. 50–55, 2019, doi: 10.25047/jtit.v6i2.109.

- [22] W. Li, P. Liu, Q. Zhang, and W. Liu, "An improved approach for text sentiment classification based on a deep neural network via a sentiment attention mechanism," *Future Internet*, vol. 11, no. 4, 2019, doi: 10.3390/FI11040096.
- [23] E. Fauziningrum, M. Pd and M. P. Encis Indah Suryaningsih, S.T., "Evaluasi Dan Prediksi Penguasaan Bahasa Inggris Maritim Menggunakan Metode Decision Tree Dan Confusion Matrix (Studi Kasus Di Universitas Maritim Amni)," *Angewandte Chemie International Edition*, 6(11), 951–952., pp. 5–24, 2021.
- [24] Widia, Z. Y. Aqsalia, S. Sari, N. U. Khoirunisa, and F. Kurniawan, "Optimasi Algoritma Naive Bayes Untuk Menganalisis Sentimen Pada Konten Pemindahan Ibu Kota di Youtube," *Journal of Computer and Information Systems Ampera*, vol. 5, no. 2, pp. 68–83, 2024.
- [25] C. Yulianto, "Model Penilaian Tanah Massal Berbasis Parcel-Based Mass Valuation Using Random Forest in Surakarta City," pp. 26–39, 2024.
- [26] A. M. Widodo, Y. S. Anggraeni, N. Anwar, A. Ichwani, and B. A. Sekti, "Performansi K-NN, J48, Naive Bayes dan Regresi Logistik sebagai Algoritma Pengklasifikasi Diabetes," *Prosiding SISFOTEK*, vol. 5, no. 1, pp. 27–33, 2021, [Online]. Available: https://scholar.google.com/citations?view_op=view_citation&hl=en&user=FOwZ8hUAAAAJ&pagesize=100&citation_for_view=FOwZ8hUAAAAJ:a3BOISfXSfwC

Tulisan berwarna hijau akan diedit sendiri oleh tim editor